

FET445 - Veri Madenciliđi Final Projesi

Spotify Şarkı Popüleritesi Tahmini

Akatsuki

Video: <https://www.youtube.com/watch?v=DdPW1zFDwWE>

Ahsen Hatipođlu (22040301055)

Ali Eren Kamalıođlu (22040301081)



Proje Tanımı ve Amaç



Problem

Şarkıların akustik özelliklerine dayanarak "Hit" (Popüler) veya "Flop" (Popüler Değil) olacağını tahmin etmek.



Veri Seti

Kaggle Spotify 1.2M+ Songs Dataset. 1.2 milyon satır veri.
Özellikler: Danceability, Energy, Acousticness vb.



Hedef

Müzik endüstrisi için veriye dayalı stratejiler geliştirmek ve "Hit" şarkıları erkenden tespit etmek.

Veri Hazırlama Süreci

- 🎵 **Veri Temizliği:** Sayısal olmayan sütunlar (Sanatçı Adı, Şarkı Adı) çıkarıldı. Eksik veriler temizlendi.
- 🎵 **Hedef Değişken:** Popularity > 50 ise "1" (Hit), değilse "0" (Flop) olarak etiketlendi.
- 🎵 **Ölçekleme (Scaling):** Derin öğrenme modelleri için kritik olan StandardScaler uygulandı.
- 🎵 **Eğitim/Test Ayrımı:** %80 Eğitim, %20 Test olacak şekilde StratifiedKFold kullanıldı.

```
df['is_hit'] = np.where(df['popularity'] > 50, 1, 0)
```

```
X = df.drop(columns=['is_hit'])  
y = df['is_hit']
```

```
scaler = StandardScaler()  
X_scaled = scaler.fit_transform(X)
```

Sınıf Dengesizliği


Veri setimizde ciddi bir sınıf dengesizliği (Imbalance) tespit edilmiştir.

🎵 **Flop (0):** %75.6 (Çoğunluk Sınıfı)


🎵 **Hit (1):** %24.4 (Azınlık Sınıfı)

Bu durum, modellerin "Flop" sınıfına eğilimli olmasına neden olmaktadır. Başarıyı ölçmek için sadece Accuracy değil, **F1 Score** ve **AUC** metrikleri kritik önem taşır.

Veri Seti Sınıf Dağılımı (Ali Eren)



Veri Seti Sınıf Dağılımı (Ahsen)



Yaklaşım 1: Feature Selection & XGBoost (Ali Eren)

▼ Feature Selection

Model karmaşıklığını azaltmak için **ANOVA F-value** testi kullanıldı (SelectKBest).

En ayırt edici **5 özellik** seçilerek model eğitildi.

🚀 Gelişmiş Modeller

XGBoost (Extreme Gradient Boosting): Tabular verilerde en yüksek performansı gösteren algoritma.

PyTorch Residual DNN: Artık bağlantılar (skip connections) kullanan özel derin öğrenme mimarisi.

Yaklaşım 2: PCA & LightGBM (Ahsen)

🔍 Boyut İndirgeme (PCA)

Büyük veri setini sıkıştırmak için **Principal Component Analysis** uygulandı.

Veri, varyansı koruyan **4 temel bileşene** indirgendiydi.

⚡ Gelişmiş Modeller

LightGBM: Hızlı eğitim süresi ve yüksek başarısı nedeniyle tercih edildi.

PyTorch MLP (Dropout): Overfitting'i önlemek için Dropout katmanları içeren Çok Katmanlı Algılayıcı.

Derin Öğrenme Mimarisi (PyTorch)

Proje kapsamında `torch.nn` kütüphanesi ile özel sinir ağıları tasarlanmıştır:



- 🎵 **Loss Function:** BCELoss (Binary Cross Entropy)
- 🎵 **Optimizer:** Adam (Adaptive Moment Estimation)
- 🎵 **Activation:** Gizli katmanlarda ReLU, çıkışta Sigmoid.
- 🎵 **Özel Teknikler:**
 - 🎵 Residual Connections (Eren)
 - 🎵 Dropout Regularization (Ahsen)



ROC Eğrisi Analizi

Modellerin ayırt etme yeteneği ROC eğrileri ile analiz edilmiştir.

- 🎵 **XGBoost (AUC: 0.86):** En geniş alanı kaplayarak en iyi ayırtırmayı yapmıştır.
- 🎵 **LightGBM (AUC: 0.84):** PCA uygulanmasına rağmen performansı çok yakındır.
- 🎵 **Base Modeller:** Eğrinin altında kalarak daha düşük performans göstermiştir.



Genel Performans Karşılaştırması

Model	Yaklaşım	Accuracy	F1 Score	AUC Score
XGBoost (Eren)	Feature Selection	0.82	0.54	0.86
LightGBM (Ahsen)	PCA	0.80	0.42	0.84
Decision Tree (Base)	Baseline	0.78	0.31	0.73
PyTorch MLP (DL)	Deep Learning	0.76	0.19	0.71
Naive Bayes (Base)	Baseline	0.59	0.39	0.60

*En iyi modeller yeşil ile vurgulanmıştır.

En İyi Model Detayları: XGBoost (Advanced)

MODEL KONFIGÜRASYONU

- Yöntem: RandomizedSearchCV ile Optimize Edildi
- n_estimators: 100
- learning_rate: 0.1
- max_depth: 6
- scale_pos_weight: Aktif (Dengesiz veri yönetimi için)
- eval_metric: 'logloss'



FEATURE SET (SEÇİLEN ÖZELLİKLER)

Modelin karar verirken kullandığı en ayırt edici 5 özellik:

- Acousticness (Akustiklik)
- Instrumentalness (Enstrümantallık)
- Danceability (Dans Edilebilirlik)
- Energy (Enerji)
- Loudness (Ses Şiddeti)

(Yöntem: SelectKBest - ANOVA F-value)



SONUÇ: AUC: 0.86 | Accuracy: %82.07 | F1 Score: 0.54

Sınıf Bazlı Performans ("Hit" Problemi)

En iyi modelimiz olan **XGBoost**'un detaylı analizi:

95%

Flop (0) Recall

Başarısız şarkıları tanıma oranı çok yüksek.

43%

Hit (1) Recall

Base modellerde %7 olan oran %43'e çıkarıldı.

Sınıf dengesizliği nedeniyle "Hit" şarkıları yakalamak daha zordur, ancak gelişmiş modeller ile bu oran ciddi seviyede artırılmıştır.

Değerlendirme ve Çıkarımlar

- 🎵 **Tabular Veri Hakimiyeti:** Bu tip yapısal verilerde Tree-based ensemble modeller (XGBoost, LightGBM), Derin Öğrenme modellerinden daha iyi sonuç vermiştir.
- 🎵 **Derin Öğrenme Zorluğu:** DNN modelleri sınıf dengesizliğine karşı daha hassas davranmış ve çoğunluk sınıfına (Flop) overfit olmaya meyilli olmuştur.
- 🎵 **Feature Engineering Etkisi:** Tüm özellikleri kullanmak yerine Feature Selection (Seçme) ve PCA (Sıkıştırma) yapmak, işlem yükünü azaltırken başarıyı korumuş veya artırmıştır.

Sonuç

Projenin kazananı **0.86 AUC** skoru ile **XGBoost** modeli olmuştur.

Gelecek çalışmalarda "Hit" sınıfı örneklerini artırmak için **SMOTE (Sentetik Veri Çoğaltma)** tekniği kullanılarak başarımlar daha da artırılabilir.

Teşekkürler

Sorularınız?

 github.com/ahsenhatipoglu/veri-madenciligi-spotify-analiz




Image Sources



<https://www.slidekit.com/wp-content/uploads/2024/11/Spotify-PowerPoint-Template.jpg>

Source: www.slidekit.com



<https://media.istockphoto.com/id/1488728999/vector/pie-chart-split-ratio-25-blue-and-75-red-for-designing-reports-about-business-profits.jpg?s=612x612&w=0&k=20&c=OMGapcun4iZnc2ChD3co3urCApBn4ll3ZhVePkvw6Hw=>

Source: www.istockphoto.com




<https://images.presentationgo.com/2025/04/abstract-neural-network-background.png>

Source: www.presentationgo.com



<https://docs.datarobot.com/en/docs/images/wb-compare-2.png>

Source: docs.datarobot.com



https://img.freepik.com/free-photo/abstract-dark-background-with-green-lines-generative-ai_169016-30616.jpg?semt=ais_hybrid&w=740&q=80

Source: www.freepik.com